

淘宝双十一美妆产品数据分析

曾伊 (202421090093)

2026-06-06

1 引言

近年来，电商已成为中国零售市场的核心增长引擎。以“双十一”为代表的电商大促活动，不仅是消费者的购物狂欢节，更是观察市场格局、品牌竞争与消费者行为的天然实验场。公开数据显示，2022 年双十一期间，全网电商交易额突破万亿元，其中美妆护肤品类以其高客单价、高复购率和高社交属性，持续占据品类销量前列。

然而，大促期间的美妆市场竞争也日趋白热化。品牌方不仅面临同质化产品的价格搏杀，还需在消费者注意力极度分散的环境中找到差异化的竞争路径。在此背景下，深入分析双十一美妆交易数据，揭示品牌竞争态势、以及口碑的传播规律，对于品牌优化运营策略、平台完善推荐机制均具有重要现实意义。## 问题背景随着电商行业的发展，双十一似乎已经成为每年特定的节日，每到双十一，网购数量激增，而美妆行业在其中占比较多，是一个值得分析的方面；在大促销带来的销量爆发背后，也隐藏着诸多待解的运营难题：不同品牌采取了截然不同的竞争策略，有的依靠低价走量，有的坚守高价定位，其效果如何？不同细分品类之间，消费者对价格的敏感度是否存在根本性差异？用户的评论行为是销量的被动伴随，还是可以被主动激励的营销杠杆？分析双十一期间的消费数据，可以对消费价格，平台政策进行分析，了解其中占优势的品牌，为企业的持续性发展提供数据支撑。## 研究目的与提出问题 1. 分析品牌销售情况，得到美妆行业的市场格局，并得出哪种类型的美妆产品销售最好。2. 分析销售量与评论量是否存在显著性关系，分析不同品牌或品类评论与销量之间的差异。

2 数据获取（来源）、解释和预处理

我们从 Heywhale 网站得到了 2022 年淘宝双十一的美妆数据，对数据进行基本的可视化，预处理，先导入必要的包并读取文件

```
1 import numpy as np
2 import pandas as pd
3 import string
4 import builtins
5 beauty_data=pd.read_excel('./双十一销售数据.xlsx')
```

2.1 数据清洗，整理

查看 df 数据框得知,包含 update_time,id,title,price,sale_count,comment_count,店名等信息，但可以看出其中 update_time,id 对后续的分析作用不大，可以省略用 drop 函数，店名就是品牌名，减少了难度，但是 title 列的信息太过冗杂，应当进行精简，可以自定义一个函数，对 title 里面的关键字进行提取，整合分类，另

外，数据框中存在缺失值，所以应该去除，因为数据有两万多条，去除缺失值对分析没太大影响。title 中的关键字可以包括：

表 1 关键字表格

类别	关键字
洁面	洗面奶、洁面、洁颜、洁面乳、洁面膏、洁面泡沫
爽肤水/化妆水	水、爽肤水、精华水、柔肤水、化妆水、保湿水
乳液	乳液、乳、肌活乳、保湿乳
面霜	霜、面霜、滋润霜、保湿霜、日霜、晚霜
精华	精华、精华液、精华露、原液
面膜	面贴膜、眼膜、面膜
套装	套装、礼盒、组合、套盒
防晒/隔离	防晒、隔离、BB 霜、CC 霜
露	露，活肤露、保湿露
其他	没有归入以上类别

```

1 keep_data=['title','price','sale_count','comment_count','店名']
2 beauty_data=beauty_data[keep_data]
3 #去除缺失值
4 beauty_data=beauty_data.dropna()
5 #自定义函数
6 def classify_product(title):
7     title=str(title)
8     if any(word in title for word in ['套装','礼盒','组合','套盒']):
9         return '套装'
10    if any(word in title for word in ['精华','精华液','原液','精华露']):
11        return '精华'
12    if any(word in title for word in ['面膜','面贴膜','眼膜']):
13        return '面膜'
14    if any(word in title for word in ['防晒','隔离','BB霜','CC霜']):
15        return '防晒/隔离'
16    if any(word in title for word in ['洗面奶','洁面','洁颜','洁面乳','洁面膏',
17        '洁面泡沫']):
18        return '洁面'
19    if any(word in title for word in ['乳液','乳','肌活乳','保湿乳','露','保湿
20        露','活肤露']):
21        return '乳液/露'
22    if any(word in title for word in ['霜','面霜','滋润霜','保湿霜','日霜','晚
23        霜']):
24        return '面霜'
25    if any(word in title for word in ['水','爽肤水','柔肤水','化妆水','保湿水'
26        ]):
27        return '爽肤水'
28    return '其他'
29 beauty_data['category']=beauty_data['title'].apply(classify_product)
30 beauty_data['brand']=beauty_data['店名']
31 beauty_data=beauty_data.drop(columns=['店名'])


```

3 进行宏观市场分析

进行宏观市场分析，我们可以探究各个品牌的竞争态势，从总销售额，总销量，平均价格，商品的丰富程度这几个方面进行分析，揭示各个品牌线上运用策略，分析中要通过图表进行数据可视化，所以需先载入必要的包和声明一些必要的操作。

首先创建一个新的数据框，新的数据框包括，总销售额，总销售量，评价价格商品数量，利用 `agg()` 函数进行简化运算求总销售额，总销量，平均价格等等，降序排序存为 excel 表格，可初步知道销售情况。

```
1 import matplotlib.pyplot as plt
2 import seaborn as sns
3 import openpyxl
4 plt.rcParams['font.sans-serif']=['SimHei','Arial Unicode MS']
5 plt.rcParams['axes.unicode_minus']=False
6
7 beauty_data['total_sales']=beauty_data['price']*beauty_data['sale_count']
8 macro_stats=beauty_data.groupby('brand').agg(
9     total_sales=('total_sales','sum'),
10    sale_count=('sale_count','sum'),
11    price_bar=('price','mean'),
12    salescounts=('title','count')
13 ).sort_values(by='total_sales',ascending=False) #降序
14 #得到macro_stats,可以存为excel表格
15 macro_stats.to_excel('macro_stats.xlsx',index=False)
16 #画出前10销售额品牌的柱状图
17 plt.figure(figsize=(7,5))
18 sns.barplot(x=macro_stats.index, y=macro_stats['total_sales'], palette='
    viridis')
19 plt.title('双十一美妆品牌总销售额排名')
20 plt.ylabel('总销售额')
21 plt.xlabel('品牌')
22 plt.xticks(rotation=60)
23 plt.tight_layout()
24 plt.show()
25 #柱状图
```



可以看到总共 19 个品牌，其中”相宜本草”和”欧莱雅”总销售额最高，在美妆品牌中属于头部品牌。接下来通过下面的分析，可以知道”相宜本草”,“欧莱雅”这两个品牌销售额与其他品牌相比为何会显著突出的原因，提取使销售额提升的因素有哪些。将销售量与评价价格之间的关系形成气泡图进行分析

```


1 macro_stats['sale_count_w'] = macro_stats['sale_count'] / 10000
2
3 plt.figure(figsize=(11, 7))
4 scatter = sns.scatterplot(
5     data=macro_stats,
6     x='sale_count_w',
7     y='price_bar',
8     size='total_sales',
9     sizes=(100, 1500),
10    hue=macro_stats.index,
11    legend=False,
12    alpha=0.7
13 )
14
15 for brand in macro_stats.index:
16     x = macro_stats.loc[brand, 'sale_count_w']
17     y = macro_stats.loc[brand, 'price_bar']
18     plt.text(x, y, brand, fontsize=9, ha='center', va='bottom')
19
20 x_padding = (macro_stats['sale_count_w'].max() - macro_stats['sale_count_w'].
21             min()) * 0.2
22 y_padding = (macro_stats['price_bar'].max() - macro_stats['price_bar'].min())
23             * 0.2

```

```

22 plt.xlim(macro_stats['sale_count_w'].min() - x_padding,
23          macro_stats['sale_count_w'].max() + x_padding * 2)
24 plt.ylim(macro_stats['price_bar'].min() - y_padding,
25          macro_stats['price_bar'].max() + y_padding)
26
27 plt.title('品牌竞争战略画像：规模 vs 定位', fontsize=14)
28 plt.xlabel('总销量（万件）', fontsize=12)
29 plt.ylabel('平均价格（元）', fontsize=12)
30 plt.grid(True, alpha=0.3)
31 plt.tight_layout()
32 plt.show()
33 # 气泡图

```



得到如上气泡图，是将 macro_stats 的数据可视化的结果，通过描述性分析可以看出，“相宜本草”通过”亲民”的价格来提升销售额，也就是所谓的”薄利多销”，“欧莱雅”品牌与之相似，同时也可知道”娇兰”这个品牌销售额不高的原因：平均价格是 19 个品牌中最高的，定位的是高消费群体，大部分人都不会选择价格昂贵的美妆产品。

4 统计推断：价格、评论与销量的关系

通过观测可以推断出，价格，评论与销量的关系，初步得出：价格与销量呈负相关关系，评论量与销量也呈正相关关系，但是这样的推导缺乏理论依据，不能作为确切的结论，需对这三个变量进行统计分析。分为两部分，一是分析价格与销量的关系，二是分析评论量与销量的关系。第一部分，可以将价格设置为解释变量，销量设置为被解释变量

4.1 价格与销量的关系

根据计量经济学知识，求价格与销量之间的相关程度，首先就要通过散点图，初步判断其整体趋势，虽然上面气泡图也可看出，但散点图更加清晰，利于做出更科学的判断。但是初步的判断没有理论依据的支撑，对此可以引入 Spearman 相关系数来辅助推断。系数值区间在 $[-1,1]$ 之间，为了运用 Spearman 相关系数，需要导入 Scipy 包里面的 stats

Spearman 系数：


$$\rho = 1 - 6 \sum d_i^2 / n(n^2 - 1)$$

其中：

n: 数据对个数

d_i : 第 i 对数据的秩序差

```
1 plt.figure(figsize=(7,5))
2 sns.scatterplot(data=beauty_data,x='price',y='sale_count',alpha=0.3)
3 plt.xscale('log')
4 plt.yscale('log')
5 plt.title("价格与销量关系的散点图")
6 plt.xlabel("价格")
7 plt.ylabel('销量')
8 plt.grid(True,alpha=0.3)
9 plt.show()
10 #价格与销量散点图
```



得到散点图后观察，得到价格与销量大致呈负相关关系，价格越高，销量越低。继续求 Spearman 相关系数得更精确关系：

```
1 from scipy import stats
2 corr,p_value=stats.spearmanr(beauty_data['price'],beauty_data['sale_count'])
3 print(f'Spearman相关系数和 P 值: {corr},{p_value:3e}')
1 Spearman相关系数和 P 值: -0.45449365426654065,0.000000e+00
```

得到 Spearman 相关系数为负，p 值 <0.01，说明该负相关关系在统计上显著。但是以上是对整体进行的分析，散点图非常密集，不容易看出各个品牌中的影响，即简单的全局回归可能掩盖不同品类间的异质性，对不同的品牌分组进行分析是有必要的。

```
1 #用for循环读取beauty_data的数据
2 categories=beauty_data['category'].unique()
3 result=[]
4 for x in categories:
5     subset=beauty_data[beauty_data['category']==x]
6     if len(subset)>10:
7         corr,p=stats.spearmanr(subset['price'],subset['sale_count'])
8         result.append({'品类':x,
9                        '相关系数':corr,
10                       'p值':p,
11                       '样本量':len(subset)})
12 corr_sort=pd.DataFrame(result).sort_values('相关系数')
13 corr_sort
```

	品类	相关系数	p 值	样本量
8	防晒/隔离	-0.578702	1.509717e-142	1587
5	爽肤水	-0.562697	1.124757e-271	3260
7	其他	-0.527709	2.019090e-275	3855
6	面膜	-0.487097	5.279754e-81	1344
3	洁面	-0.484114	2.900909e-136	2314
2	精华	-0.476018	9.691370e-160	2825
0	面霜	-0.447396	4.982362e-159	3235
4	套装	-0.442689	1.367576e-202	4231
1	乳液/露	-0.383108	2.022945e-91	2593

得到的 corr_sort 表格中可以看出，所有品类的化妆品其价格与销量的相关系数都呈负相关关系，且 p 值都很小，说明所有品类的负相关关系在统计上是显著的，且样本量都呈大样本，可信度较高。

4.1.1 进一步分析

在得知价格和销量之间确实有明显的负相关关系后，我们可以进一步分析，对于不同品类，价格的变化对销量的影响有什么不同，对此我们可以引入一个经济学

概念：价格弹性。即价格变化 1%，销量相对于变化多少，本节采用 Spearman 相关系数为代理指标，取值范围 [-1,1]，绝对值越大，说明消费者对价格越敏感，越富有弹性。观察 corr_sort 表格，看出”乳液/露”品类的相关系数最小，但是所有的系数绝对值差异不是特别大，说明在美妆行业，没有什么品类是完全不受价格影响的，但其敏感程度存在梯度，比如：

表 3 弹性梯队

弹性梯队	品类	相关系数范围	含义
高敏感梯队	防晒/隔离、爽肤水	-0.579~-0.563	价格敏感度最高，低价更容易吸引消费者，消费者对品牌的忠诚度低
中敏感梯队	其他、面膜、洁面精华、面霜	-0.528~-0.447	价格有一定影响力，但不是唯一决策因素，功效与品牌也有一定影响
低敏感梯队	套装、乳液/露	-0.443~-0.383	敏感度最低，说明消费者更看重组合价值，或

产品的质地

看出防晒类产品并非价格最低，但价格敏感度最高，结合双十一的背景分析，可能与双十一的特殊背景有关：防晒属于季节性产品，消费者习惯于在其期间囤货，另外不同产品的核心功能高度同质，这增加了各个产品的替代效应，从而使得消费者对价格的敏感度随之上升。另外套装、乳液的价格敏感度相对最低，可以归因于二者不同的心理机制。套装通常是通过礼盒或组合装出售，其产品组合的复

杂程度和套装的附加价值模糊了价格之间的比较，或者说，用户在套装和单一产品之间，有时为了方便还是会选择套装；而乳液/露作为保湿类品，消费者可能已经形成较强的品牌习惯和忠诚度，不太容易因价格的波动而选择其他品类。

综上所述，在双十一大促这一特殊背景之下，所有的美妆品类无法摆脱价格竞争，但是不同的品类之间存在着有差异化的价格响应模式，因此可以提出以下建议：针对防晒、爽肤水等高敏感品类，直接的价格折扣仍是驱动消费的最有效手段；而对于套装、乳液等品类，则可将营销重点更多地放在产品组合设计、品牌忠诚度培养等非价格策略上。


下面通过代码，画出箱线图，横轴是价格区间，纵轴销量，同时区分各个品类，通过观察箱线图也可得到类似结论。其中随着价格区间上升，销量的中位数呈下降趋势，说明价格与销量呈反方向变动关系。通过图形更加直观清晰，当价格区间从 [0,50] 上升到 [50,100] 时大部分的销量都下降较多，说明 [0,50] 与 [50,100] 区间是一个分位点，大部分消费者倾向于较为亲民的价格，如果价格提升至 [50,100]，产生的替代效应较为明显，消费者可能选择不购买此类商品。但是，我们可以看出图形中仍有特例，比如说观察“精华”的箱线图，价格区间在 [50,100] 的中位数竟然比在 [0,50] 的中位数高，说明 [50,100] 的精华反而购买的人还多些，即价格-需求关系并非普遍成立；这是因为在一定条件下，高价可能因质量暗示而使增加需求，消费者对每种产品存在一个“可接受的价格范围”，即有心理上的价格下限和上限。价格过低会认为“太便宜不可靠”，过高则认为“太贵”[1]。另外从总体分析，即之前说的价格与销量之间的关系在箱线图中似乎并不明显。这是因为价格确实会影响消费者对质量的感知，但品牌、价格的差异大小、实验设计都会左右这个效应的强弱 [2]；通俗来说，得到价格影响销量不显著的结论，并不能说明这个结论没有意义，在统计上或许不显著，因为影响因素有很多，这些因素左右了最终的结果。大体上价格与销量之间呈负相关关系。

```
1 beauty_data['price_bin'] = pd.cut(  
2     beauty_data['price'],  
3     bins=[0, 50, 100, 150, 200, 300, 1000],  
4     labels=['0-50', '50-100', '100-150', '150-200', '200-300', '300+']  
5 )  
6 main_cats = ['洁面', '爽肤水', '乳液/露', '面霜', '精华', '面膜', '套装', '防晒/  
   隔离']  
7 df_plot = beauty_data[beauty_data['category'].isin(main_cats)]  
8  
9 g = sns.catplot(  
10     data=df_plot,  
11     x='price_bin',  
12     y='sale_count',  
13     col='category',  
14     col_wrap=3,  
15     kind='box',  
16     height=4,  
17     aspect=1.2,  
18     fliersize=1.5,  
19     color='steelblue'  
20 )
```

```

21
22 g.set_axis_labels("价格区间（元）", "销量")
23 g.set(yscale='log')
24 g.set_titles("{col_name}")
25 g.fig.suptitle("各品类在不同价格区间的销量分布", y=1.02, fontsize=14)
26 plt.tight_layout()
27 plt.show()
28 #得箱线图:

```



```

1 #接下来单独分析"精华"品类价格与销量关系
2 essence = beauty_data[beauty_data['category'] == '精华']
3 essence_price_stats = essence.groupby('price_bin', observed=False).agg(
4     平均销量=('sale_count', 'mean'),
5     中位数销量=('sale_count', 'median'),
6     产品数量=('title', 'count')
7 ).reset_index()
8
9 essence_price_stats

```

	price_bin	平均销量	中位数销量	产品数量
0	0-50	6027.486607	1426.5	224
1	50-100	28693.599156	6498.0	237
2	100-150	16402.427481	2536.0	262

	price_bin	平均销量	中位数销量	产品数量
3	150-200	2769.649289	1677.0	211
4	200-300	6057.537133	1827.0	579
5	300+	3084.181542	683.0	986

对”精华”品类数据进行简单描述性统计看出，[0,50],[50,100] 平均销量从 6 千飙升到 2.8 万，翻了几倍，中位数也从 1 千多涨到 6 千多。这证实了上面的”低价不被信任”的理论。下面证明”精华”品类 [0,50],[50,100] 两个价格区间和销量有显著差别，采用 Mann-Whitney u 检验，公式为：

$$U = \min \left(n_1 n_2 + \frac{n_1(n_1 + 1)}{2} - R_1, n_1 n_2 + \frac{n_2(n_2 + 1)}{2} - R_2 \right)$$

n_1, n_2 为两样本容量， R_1, R_2 为两样本秩和，这里分别指价格区间和销量，而且在大样本下 U 近似服从正态分布，可以转换成 Z 统计量检验，代码：

```
1 essence = beauty_data[beauty_data['category'] == '精华']
2 low = essence[essence['price_bin'] == '0-50']['sale_count']
3 mid = essence[essence['price_bin'] == '50-100']['sale_count']
4 u_stat, p_val = stats.mannwhitneyu(low, mid, alternative='two-sided')
5
6 print(f"U统计量: {u_stat},p值: {p_val}")
7 if p_val < 0.05:
8     print("两个价格区间的销量差异统计显著")
9 else:
10    print("差异不显著")

1 U统计量: 15318.5,p值: 4.1055596972211574e-15
2 两个价格区间的销量差异统计显著
```

经 Mann-Whitney U 检验，两个价格区间的销量差异具有统计学显著性 ($U=15318.5, p<0.05$)，排除了差异由随机扰动项导致的可能性，使推论有了理论依据的支撑。


另外表格中 [200,300] 的平均销量较 [150,200] 出现了小幅度回升。这可能反映了一部分消费者对”中高端精华”的认可，当跨过 200 元门槛，消费者开始期待更强的功效和更好的使用体验，愿意为此支付溢价。然而，300 元以上区间的中位数销量骤降至 683，且该区间聚集了最多的产品数量（986 个），表明超高价精华市场虽然产品众多，但真正能够获得消费者认可的仍是少数头部品牌，大部分品牌在高价精华市场不能获利。这一现象可以由 Veblen（1899）关于炫耀性消费的论述来解释，消费行为中参杂着”自我奖赏”与”身份认同”的动机，能够承载这种符号价值的往往是那些具备足够品牌资产的高端品牌。所以说精华品类的”倒 U 型”价格-销量关系并非是对需求定律的驳斥，而是对需求定律在信息不对称市场中的深化理解。表明价格更是一种品质信号与心理价值的载体。所以对于品牌方来说，盲目的降价不能提升销售额，反而可能会自毁品牌价值，突破消费者”合理价格下限”，适当的提升价格有时候会有利于品牌发展。

4.2 评论与销量的关系

接下来的评论与销量的分析，同价格与销量的分析方法类似：

```
1 corr_comment, p_comment = stats.spearmanr(beauty_data['comment_count'],
2       beauty_data['sale_count'])
3
4 print(f"评论与销量Spearman相关系数: {corr_comment:.4f}, p值: {p_comment:.4e}")
5
6 plt.figure(figsize=(7, 5))
7 sns.scatterplot(data=beauty_data, x='comment_count', y='sale_count', alpha
8       =0.3, s=10)
9 plt.xscale('log')
10 plt.yscale('log')
11 plt.title('评论数与销量的关系（双对数尺度）')
12 plt.xlabel('评论数（对数）')
13 plt.ylabel('销量（对数）')
14 plt.grid(True, alpha=0.3)
15 plt.tight_layout()
16 plt.show()
17 #得评论数与销量散点图
```

```
1 评论与销量Spearman相关系数: 0.8235, p值: 0.0000e+00
```




根据求得的相关系数和 p 值，肉眼看出评论量与销量之间呈显著的正相关关系，说明评论越多，销量越高。但是单纯的来看，评论与销量确实呈正相关，卖得越好的产品，自然积累的评论就越多。这其中还包含销量规模的混淆效应，所以应构造一个统计量：评论转化率；能公平地比较不同销量量级的产品在评论意愿上的差异。将评论转化率用箱线图呈现出来，最后通过 Kruskal-Wallis 检验来提供理

论支撑。Kruskal-Wallis 检验是用来比较三个或三个以上的样本分布是否有显著差异，它不要求数据呈正态分布，公式：

$$H = \frac{12}{N(N+1)} \sum_{i=1}^k \frac{R_i^2}{n_i} - 3(N+1)$$

下面展示代码：

```
1 #在beauty_data中创建评论转化率列
2 beauty_data = beauty_data[beauty_data['sale_count'] > 0]
3 beauty_data['comment_rate'] = beauty_data['comment_count'] / beauty_data['sale_count']
4 beauty_data['comment_rate']=beauty_data['comment_count']/beauty_data['sale_count']
5 plt.figure(figsize=(7,5))
6 sns.boxplot(data=beauty_data, x='category', y='comment_rate', fliersize=0.5)
7 plt.ylim(0, beauty_data['comment_rate'].quantile(0.95)) # 去掉极端值，不然对箱线图影响很大
8 plt.title('各品类评论转化率分布')
9 plt.ylabel('评论转化率（评论数/销量）')
10 plt.xticks(rotation=30, ha='right')
11 plt.tight_layout()
12 plt.show()
13 #各品类评论转化率箱线图
```



```
1 #Kruskal-Wallis 检验 代码
2 beauty_data = beauty_data[beauty_data['sale_count'] > 0]
```

```

3 beauty_data['comment_rate'] = beauty_data['comment_count'] / beauty_data['
  sale_count']
4 categories = beauty_data['category'].unique()
5 groups = [beauty_data[beauty_data['category'] == cat]['comment_rate'].dropna
  ()
6     for cat in categories if len(beauty_data[beauty_data['category'] ==
  cat]) > 10]
7 h_stat, p_valu = stats.kruskal(*groups)
8 print(f"h值: {h_stat},p值: {p_valu}")
1 h值: 489.7951352572543,p值: 1.0876040115298888e-100

```

Kruscal-wallis 检验的 p 值非常小，说明不同的品类之间评论转化率有显著差异。最后生成一个表格：

```

1 #因为在一些品类中有销量=0的产品，这使得求出的平均转化率无穷大，所以应去除：
2 beauty_data = beauty_data[beauty_data['sale_count'] > 0]
3 beauty_data['comment_rate'] = beauty_data['comment_count'] / beauty_data['
  sale_count']
4 comment_rate_by_cat = beauty_data.groupby('category').agg(
5     平均转化率=('comment_rate', 'mean'),
6     中位数转化率=('comment_rate', 'median'),
7     样本量=('comment_rate', 'count')
8 ).sort_values('平均转化率', ascending=False)
9 comment_rate_by_cat.to_excel('./comment_rate_by_cat.xlsx',index=False)
10 comment_rate_by_cat

```

	平均转化率	中位数转化率	样本量
category			
精华	2.515170	0.118644	2730
乳液/露	0.521786	0.113043	2541
防晒/隔离	0.496908	0.148565	1548
面膜	0.478982	0.120214	1308
面霜	0.359200	0.104460	3155
爽肤水	0.232993	0.114055	3138
其他	0.217757	0.119451	3779
洁面	0.190708	0.115945	2268
套装	0.131937	0.076205	4012

从表格和箱线图可以看出，中位数平均转化率最高的是防晒/隔离，而平均转化率最高的是精华，说明该品类中大多数产品的评论转化率普遍较高且分布较均匀，可能由于防晒产品的功效感知较明显：使用后是否清爽、等体验容易被消费者直观感受到，从而激发了普遍的评论意愿。而精华的平均转化率高的原因可能是由于其中有评论转化率极高的“爆款”，拉高了平均值，说明精华品类中大多数用户参与度不高，但有少数产品能激发用户的评论欲望。这就能说明为什么箱线图和表格表面上看起来不同的原因。

5 结论与建议

5.1 结论

本报告以 2022 年双十一期间淘宝美妆产品交易数据为对象，运用描述性统计、Spearman 相关分析、Mann-Whitney U 检验、Kruskal-Wallis 检验等方法，系统分析了 19 个主要品牌的竞争格局、价格弹性的品类异质性以及评论转化率的差异特征。得出：

第一、双十一美妆市场呈现出三梯队竞争格局。基于品牌销售额、销量、平均价格及 SKU 丰富度多维度分析，可将 19 个品牌划分为三种竞争模式：以悦诗风吟、妮维雅、相宜本草为代表的”规模驱动型”品牌，依靠低价格与海量 SKU 占领大众市场；以娇兰、雪花秀、雅诗兰黛为代表的”价值驱动型”品牌，凭借高定价与精选产品对标高端客群；以欧莱雅、自然堂、佰草集为代表的”均衡发展型”品牌，则在规模与价值之间取得了相对平衡。从品类维度看，“水乳面霜”作为基础护肤刚需品类贡献了最高销售额占比，而“套装”品类以高客单价成为品牌拉升销售额的重要手段。

第二，价格弹性存在显著的品类异质性，精华品类呈现”倒 U 型”价格、销量关系。Spearman 相关分析表明，所有品类的价格与销量均呈显著负相关（ $p < 0.001$ ），但相关系数绝对值从-0.58（防晒/隔离）到-0.38（乳液/露）不等，弹性强度存在明显梯度。结合价格区间箱线图的进一步分析识别出三种价格响应模式：洁面、面膜、爽肤水等基础品类属于“价格敏感型”，销量随价格上升而急剧下降；而防晒/隔离、面霜、乳液/露属于“价值锁定型”，在消费者心理舒适区内价格敏感度偏低；精华品类则呈现独特的“倒 U 型”关系——在 0-50 元低价区间销量低迷，50-100 元区间销量反而达到峰值，平均销量从 6027 件升至 28694 件，增长接近 5 倍。进一步提供 Mann-Whitney U 检验证实了这一上升段差异的统计显著性（ $p < 0.05$ ）。该现象与 Monroe（1973）提出的价格-质量推断理论一致：在信息不对称的功效型护肤品市场，过低的价格会向消费者传递负面质量信号，从而抑制购买意愿。

第三，评论转化率呈现品类间的显著差异，反映了消费者卷入度的结构性不同。Kruskal-Wallis 检验表明，不同品类的评论转化率存在显著差异（ $p < 0.001$ ）。防晒/隔离品类的评论转化率中位数居各品类之首（0.149），表明该品类的消费者具有普遍较高的评论意愿；而精华品类内部数据呈右偏分布，平均转化率受少数高值影响显著高于中位数，反映出精华市场中存在少数“爆款”产品集中获得大量评论的“头部效应”。高转化率产品相较于低转化率产品具有更高的平均价格，进一步印证了高价产品消费者心理卷入度更高、评论动机更强的推论。## 建议第一、实施差异化的品类定价策略。对于洁面、面膜等高价格弹性品类，大促期间应以有竞争力的价格折扣换取销量爆发，提高市场份额，也就是所谓的薄利多销；对于精华、套装等低弹性品类，则应警惕盲目降价进入极端低价区间。特别是精华品类，0-50 元区间的销量惨淡，这提示品牌方：功效型产品存在消费者的心理价格下限，维持该下限对于保护品牌信任与品质感知至关重要，切记不要把价格降低到下限水平，反而会使销量减少。

第二、优化口碑激励资源的投放方向。防晒/隔离、精华等评论转化率较高的品类是口碑营销的天然价值洼地，品牌可通过赠品激励、会员专属评价、使用体验分享等方式进一步放大用户评论意愿。对于评论转化率较低的品类如套装，则需反思是否存在评论激励机制设计不够精准的问题，或者把注意力集中在套装的组合价值上面来，通过更好的搭配来提升销售额。

第三、明确自身竞争定位，选择适配的品牌战略。通过气泡图显示，头部品牌已形成清晰的差异化定位。中小品牌或新进入者应根据自身资源禀赋，在“规模驱动”与“价值驱动”之间做出明确选择，选择自己的顾客是高收入群体还是低收入群体，避免陷入定位模糊、两头不靠的困境。

5.2 不足与展望

本数据集仅覆盖 2022 年双十一前后单一时间节点，属于截面数据，无法捕捉品牌竞争格局和消费者行为的季节性变化与年度趋势。未来可引入多年双十一数据或多期日常销售数据，构建面板数据模型，动态分析价格弹性和口碑效应的时序演化。另外、本研究缺乏用户画像（年龄、性别、消费层级）、订单明细以及商品详情页浏览记录等深层信息，不能分析不同群体的消费差异，也无法深入分析评论转化率差异背后的个体行为动因，若能得到用户画像，后序还可进一步进行推荐系统的构建。而且本研究对商品品类的划分依赖于 title 字段的关键词匹配规则，可能存在少量产品的错误分类（如“精华水”被归入精华品类）。未来研究可结合平台提供的标准品类标签或产品信息，进一步提升品类划分的准确性，从而提高分析的精确度。

而在数据分析方法的选择上，本研究优先采用 Spearman 相关分析、Mann-Whitney U 检验及 Kruskal-Wallis 检验等非参数方法，而不使用统计回归等参数模型。这一选择基于以下考量：

一，数据分布的客观约束。电商交易数据中的销量与评论数呈现典型的右偏分布，即少数爆款产品具有极高销量，大多数产品销量相对较低，甚至为 0，不满足线性回归模型对残差正态性与方差齐性的基本假设。若强行套用参数模型，可能导致显著性检验失真，得出误导性结论。二，研究问题的本质特征区别。本研究的核心目标是“比较”而非“预测”——比较不同品类的价格弹性、比较不同品类的评论转化率。对于这类多组比较问题，非参数检验是更直接和稳健的分析方法，而且数据有两万多条，得到的回归分析结果似乎也不能进行预测。三，方法适配性优于方法复杂度。数据分析中不存在绝对“高级”的方法，只有最适合研究问题与数据特征的方法。Spearman 相关分析能够捕捉价格与销量之间的单调关系且不限于线性关系，使研究中发现了“倒 U 型”等非线性模式。

6 收获与反思

回顾本次分析的全过程，从数据清洗到宏观描述，从描述统计到假设检验，每一步都伴随着方法的选择与权衡。最初接触这份双十一美妆数据时，也曾犹豫是否应当采用回归分析、聚类算法等更为“复杂”的方法，以体现分析的“高级”。但随着分析的深入，我逐渐知道，对于不同的数据集要使用相适应的方法，因为数据分析的最终目的是为决策者提供理论支撑。

我们不仅要把一个复杂的数据集变成一个漂亮、精炼的数据表，还需要知道其背后的原因，了解数据为什么是这样分布的，比如说文中的”精华”品类价格与销量为什么呈现 U 型，其背后的经济理论是什么，这样分析的数据才有意义，才能运用到实际中来。从这个意义上说，本次研究带给我的不仅是技术层面的锻炼，更是一次数据分析思维范式的重塑：“合适”远比“复杂”更重要，“有用”远比“花哨”更重要，这是我在完成数据分析报告过程中学到的最重要的一课。

7 参考文献

[1] :Monroe, K. B. (1973). Buyers' subjective perceptions of price. *Journal of Marketing Research*, 10(1), 70-80.

[2]:Rao, A.R.,& Monroe, K. B. (1989). The effect of price, brand name, and store name on buyers' perceptions of product quality: An integrative review.*Journal of Marketing Research*, 26(3), 351-357.